固定轨迹下验证原生Session复用

四模型统一路径、共享条件同源实验、完整边界披露

4

模型，同一套系统

128

原生输出与重算配对

768

正式性能请求

源码固定1d6099da；1535项源清单。统一评测及主机预算尚未取得。

四模型部署，明确并行和精度

每次只运行一个本组NPU实验；至多使用同一物理卡的两个chip

0.8B与4B

BF16主体，TP1。分别部署于同一张卡的一个chip。

9B

BF16主体，显式FP32输出头，TP1。保留精度与资源取舍。

27B

BF16主体，TP2，使用同卡两个64GB chip。

实际负载范围

两会话、16轮、每轮8输出；上下文增长按实际轨迹记录。

沿用统一Engine与缓存路径

复用实际已生成历史，不新增第二条推理执行路径

Engine会话

保存实际生成IDs

调度与混合缓存

MHA / GDN状态

NPU执行

复用后继续生成

工具由脚本执行求和465并等待2秒；另一会话继续推进。不是模型自主选择工具。

同源、同权重、同任务配置配对

先验证组合，再测独立Session ON/OFF性能

质量组合

原生阶段结束并关闭后，串行重算32条完整实际历史；逐ID和context分别检查。

性能两臂

Session只提交增量；重算臂提交完整历史。两臂均关闭prefix cache。

计时口径

每臂wall包含工具等待；排除模型启动、创建和关闭Session。

重复边界

三轮共享同一Engine，不是三个独立进程样本；不报告显著性或置信区间。

四模型原生组合均按实际结果审计

输出、历史、工具窗口、持页及关闭分别检查

0.8B

输出 32/32；context 32/32。工具窗口另会话完成1条；close后active=0。

4B

输出 32/32；context 32/32。工具窗口另会话完成6条；close后active=0。

9B

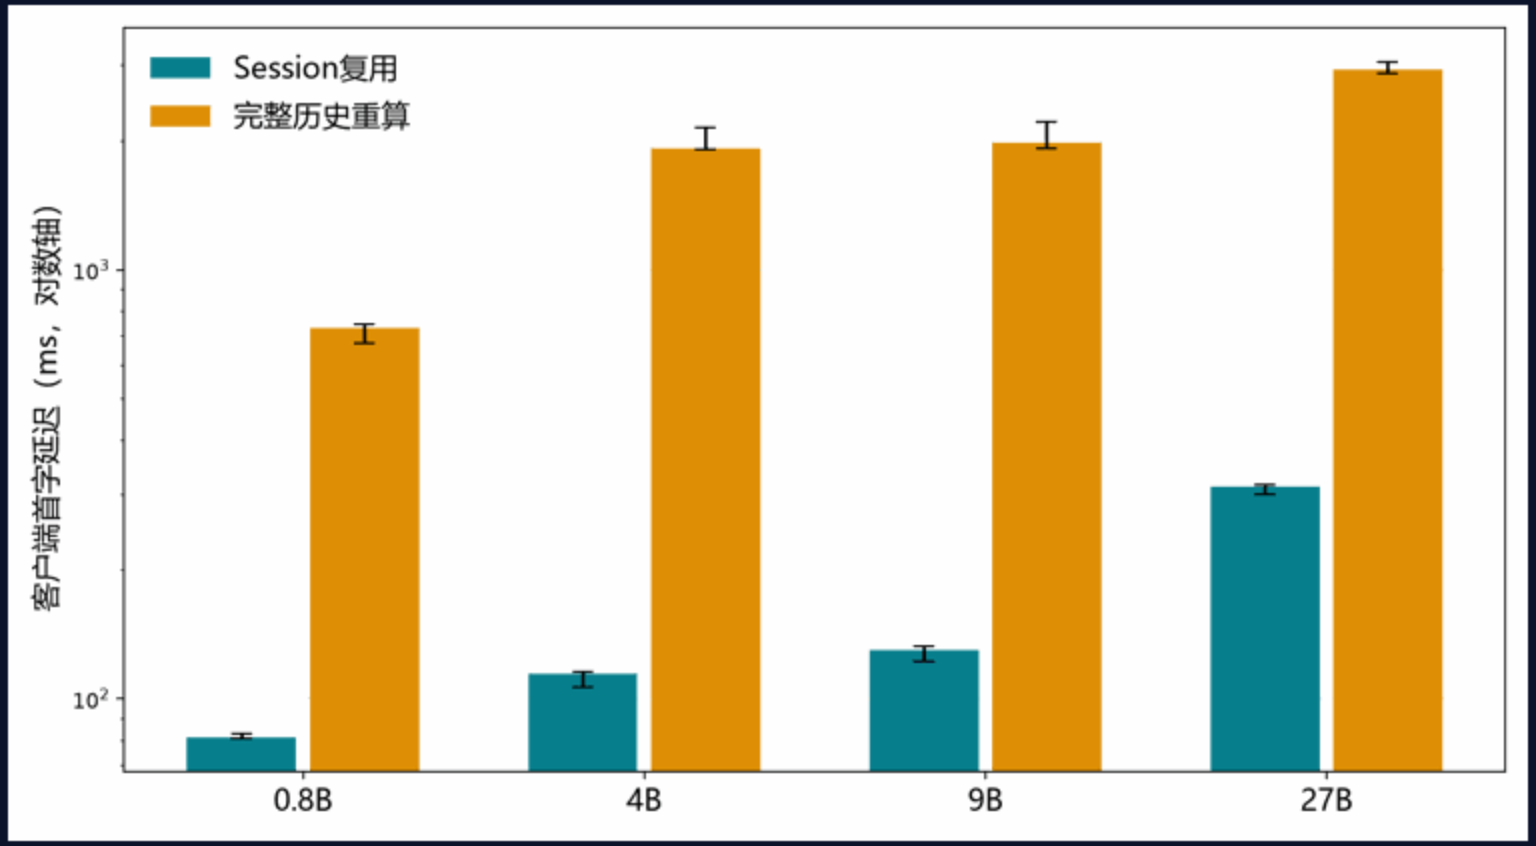
输出 32/32；context 32/32。工具窗口另会话完成6条；close后active=0。

27B

输出 32/32；context 32/32。工具窗口另会话完成3条；close后active=0。

首字延迟：按三轮各臂P50展示

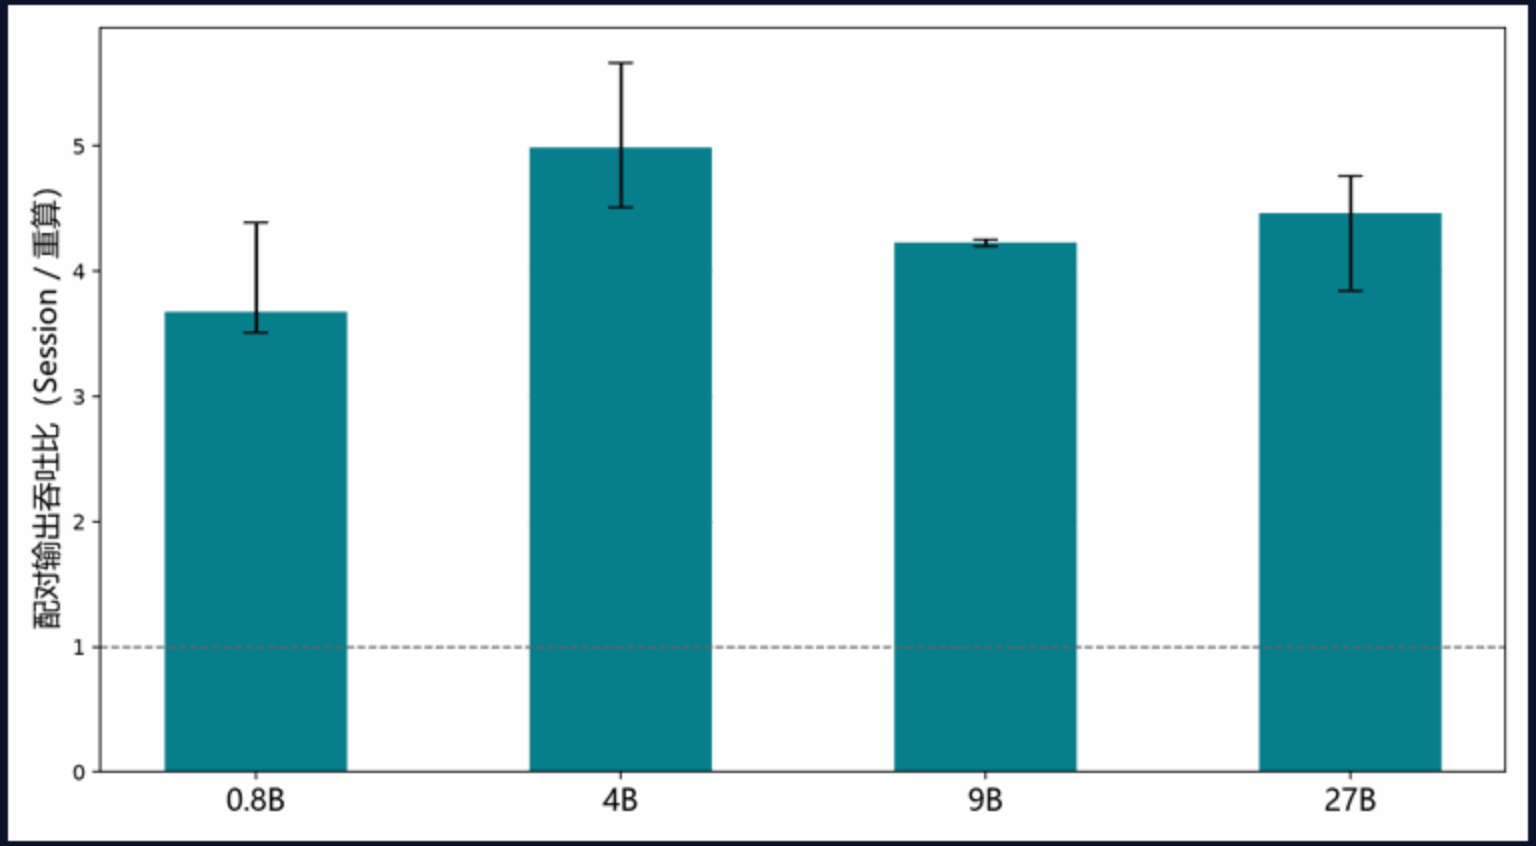
柱高为三轮各臂P50的中位数；逐ID匹配后统计



对数轴；误差线为三轮min/max，不是置信区间。包含客户端与调度开销。

吞吐：每轮配对计算再汇总

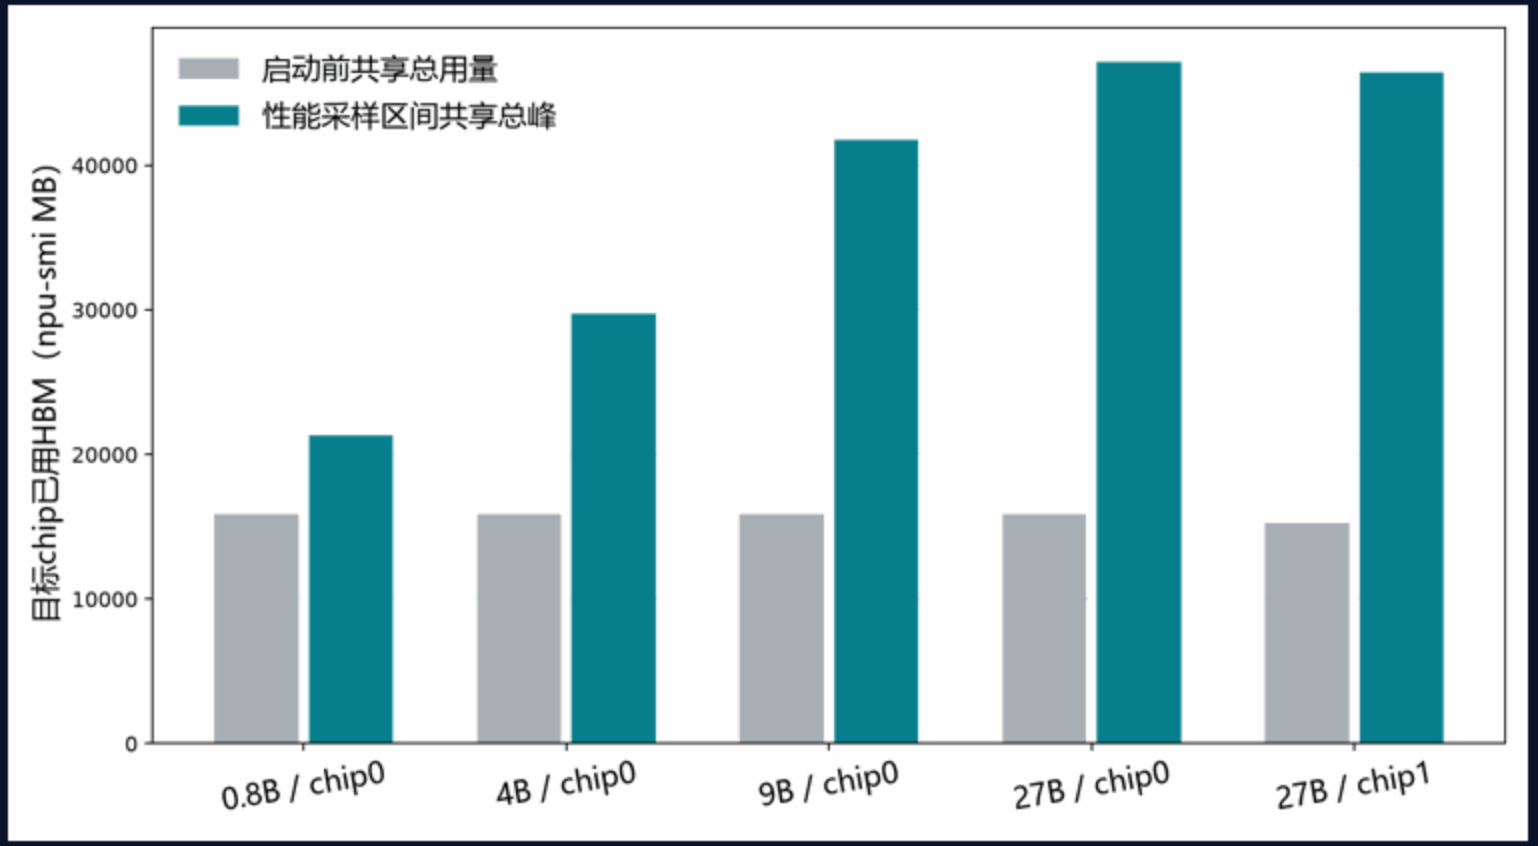
每臂256个实际输出token除以该臂wall，包含工具等待



三轮共享同一Engine；共享设备条件下的描述性结果，不保证独占收益。

资源：共享目标chip的观察HBM

保留启动前共享用量与性能采样区间总峰，不归因为纯模型占用



查询不是连续瞬时采样；总用量包含背景服务，不能用两根柱的差值证明模型净开销。

负结果与验证边界保持可见

固定轨迹一致不等于任意输入的数值或语义质量

历史差异

4B/9B短输入TP1/TP2差异继续保留；0.8B旧greedy和1%失败不被Session结果覆盖。

27B容量

旧TP1默认预算是缓存/调度容量拒绝，不是权重放不下；95%候选也不等于本轮Agent结果。

共享条件

实时PID身份、显存余量与退出检查保护原服务；轮询不是全局设备预留。

未知课程评测

统一负载、规定Kunpeng主机预算及细则尚未取得，未宣称通过。

固定源码、复现入口与成员责任

代码、实验、分析和材料均如实披露AI辅助

实现与复现

源码1d6099da，1535项。复现见docs/project/final_delivery_20261101.md。

软件验证

本地966通过/33跳过；服务器991通过/8跳过，范围分别说明。

责任边界

张晟祺：实现与部署；李书砚：正确性与协议；计然：性能与资源分析。

AI与提交

不虚构成员亲自执行、个人工时或理解考核。教学网由用户本人提交。