0.8B：单芯片与双芯片的输出吞吐

共享环境；每请求固定输出32 token；全部三轮均保留

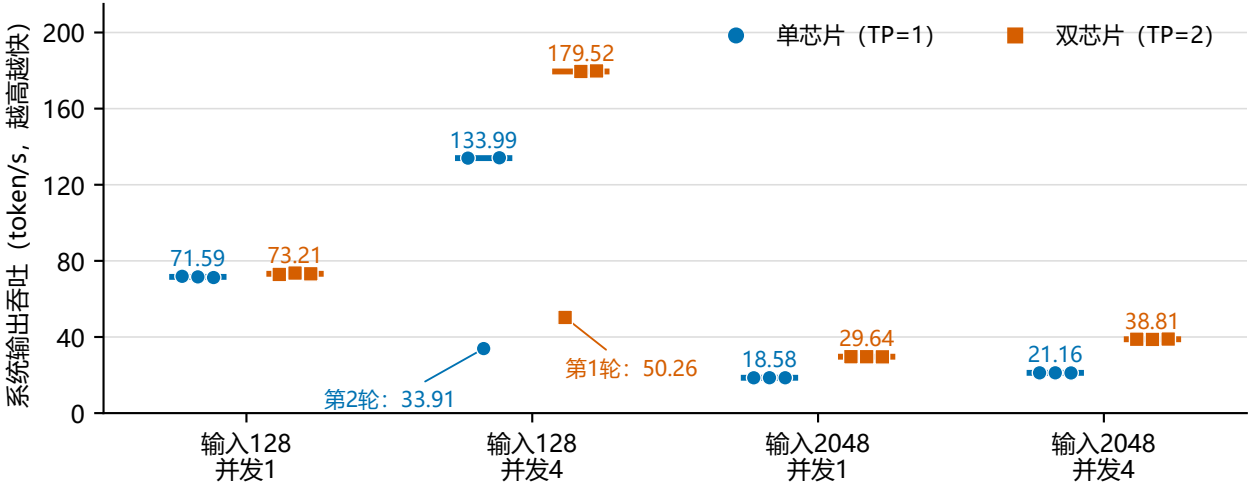

每个小点 = 一轮（8个正式请求）；横向错开仅为辨认轮次。

粗短横线及其数字 = 三轮中位数；相近的点可能重合。