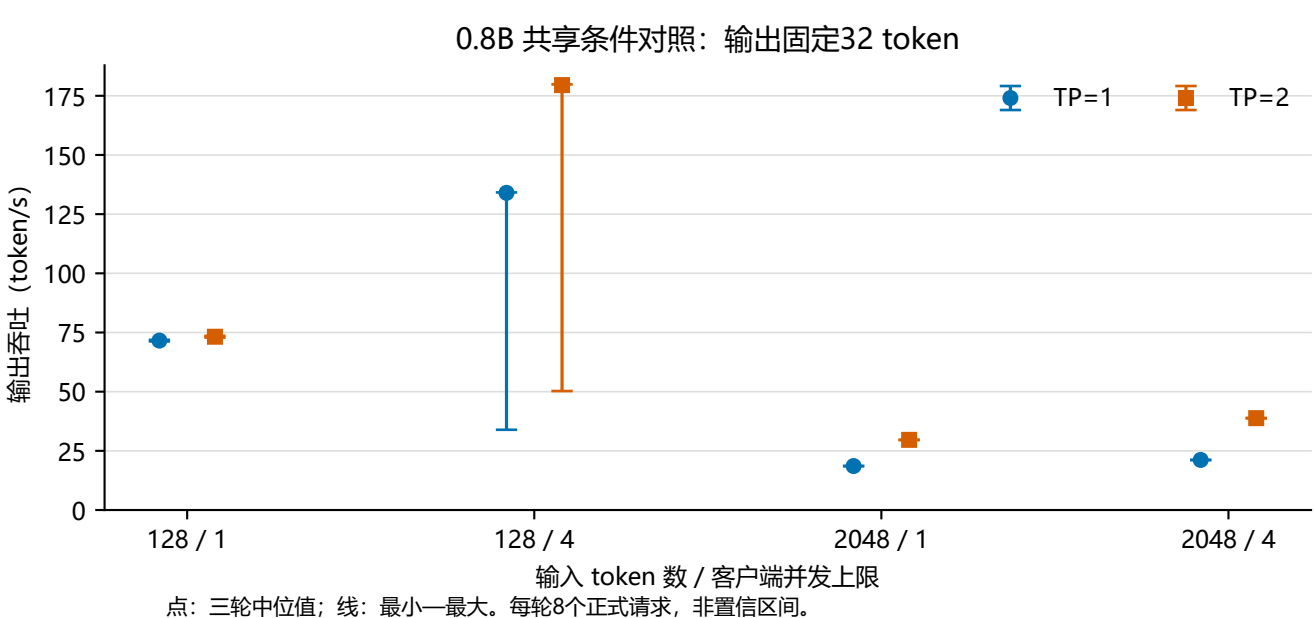
0.8B 共享条件对照：输出固定32 token
TP=1
TP=2
输出吞吐（token/s）
0
25
50
75
100
125
150
175
128 / 1
128 / 4
2048 / 1
2048 / 4
输入 token 数 / 客户端并发上限
点：三轮中位值；线：最小—最大。每轮8个正式请求，非置信区间。